

MetaboleAI — Specifica tecnica del Giudice (compliance & brand)

Specifica implementabile dallo Sviluppo per l'agente **Giudice**: il controllo che valuta **ogni** proposta di contenuto **prima** della pubblicazione e restituisce un verdetto **Approva** / **Rivedi** / **Blocca**. È il freno di sicurezza della Macchina di Marketing: protegge dagli **stop dei social** e dai **claim di salute** non validati.

Riferimenti: `Metabole_Macchina_Marketing_AI` (ruolo nella macchina), `Metabole_Libreria_Creativa` (lessico), `Metabole_Reparto_Marketing_e_Standard_CRM` (audit/consensi).

1. Ruolo e posizione nel flusso

Creativo/Copy → [GIUDICE] → (revisione umana se sensibile) → Publisher

Nessun asset raggiunge il Publisher senza un verdetto del Giudice. Ogni decisione è **registrata** (audit) e **spiegata** (motivazione), sia per imparare sia per difendersi in caso di contestazione.

2. Input / Output

Input (asset da valutare):

```
{
  id, tipo: reel|carosello|testimonianza|quote|email|sms|ad,
  canale: instagram|tiktok|meta_ads|google_ads|email|sms,
  testo, media[] (immagini/video), cta,
  targeting: {eta_min, audience, paese},
  contesto: {angolo, campagna, fase_funnel}
}
```

Output (verdetto):

```
{
  verdetto: approva | rivedi | blocca,
  punteggio: 0-100,
  violazioni: [ {regola, gravita, dove, suggerimento} ],
  richiede_umano: bool,
  motivazione: testo,
  ruleset_version
}
```

3. Ruleset di compliance (regole verificabili)

Ogni regola ha **gravità**: *bloccante* · *da rivedere* · *avviso*. Le regole vivono in `config_param` (versionate), così si aggiornano quando le policy cambiano — **senza toccare il codice**.

3.1 Trasversali (tutti i canali)

- **Prima/dopo**: immagini o testi che confrontano il corpo prima/dopo, o che mostrano trasformazioni di peso legate al prodotto.
- **Attributi personali**: seconda persona che implica una condizione ("sei in sovrappeso?", "vuoi perdere peso?", "stai lottando con i chili"). (*Riformulare sul servizio.*)
- **Numeri/tempi/garanzie**: "-X kg in Y giorni", "garantito", "cura".
- **Body-shaming / corpo ideale**: umiliazione del corpo, "corpo perfetto", aspetto = valore/ successo/felicità.
- **Claim di salute non validati**: promesse mediche/terapeutiche → **escalation nutrizionista capo**.
- **Targeting età < 18**: i contenuti dimagrimento richiedono **18+**.
- **Coerenza brand**: tono, palette, pilastri (persone vere + AI, senza fame, trasparenza).
- **Landing coerente**: la pagina di destinazione rispetta le stesse regole (privacy, contatti, no promesse).

3.2 Specifiche Meta (Facebook/Instagram)

- Framing indiretto su attributi ("per chi è in sovrappeso") oltre alla seconda persona.
- **Naming sensibile** di pixel/audience/conversioni (termini sanitari) → segnalare rinomina.
- Preferire ottimizzazione su eventi alti nel funnel (traffico/lead) per la categoria sensibile.

3.3 Specifiche TikTok

- "Facile/garantito", "dimagrisci senza dieta né esercizio", risultati irrealistici.
- Integratori dimagranti / app di digiuno (in Italia non pubblicizzabili).
- Claim di dimagrimento ammessi solo 18+ e solo promuovendo stile di vita sano.

3.4 Specifiche Google Ads

- Prodotti hCG per dimagrimento; farmaci su prescrizione senza certificazione.
- Audience "curate dall'inserzionista" su temi salute (Customer Match/Lookalike) → usare audience predefinite Google.
- Nessun body-shaming / risultati irrealistici nel testo.

3.5 Email / SMS

- Invio senza **consenso** valido per il canale (email/SMS separati).
- SMS senza opzione di **opt-out** ("STOP").
- Email: dominio autenticato (SPF/DKIM/DMARC) e mittente coerente.

4. Logica di scoring e verdetto

Il Giudice valuta **quattro dimensioni**, ciascuna 0-100, poi combina:

Dimensione	Cosa misura	Peso
Compliance	Assenza di violazioni policy (per canale)	0.45
Veridicità/claim	Nessuna promessa non sostenibile; claim salute validati	0.25
Brand	Tono, pilastri, coerenza visiva	0.20
Qualità	Chiarezza, hook, CTA, formato corretto	0.10

$\text{punteggio} = 45 * \text{Compliance} + 25 * \text{Veridicità} + 20 * \text{Brand} + 10 * \text{Qualità}$ (normalizzato 0-100)

Regole di verdetto (in ordine di precedenza): 1. Se esiste **una** violazione → **BLOCCA** (a prescindere dal punteggio). 2. Se claim di salute → **richiede_umano = true** + escalation nutrizionista capo (verdetto *rivedi* finché non validato). 3. Se una o più violazioni → **RIVEDI** (torna a Creativo/Copy con i suggerimenti). 4. Altrimenti: **APPROVA** se punteggio $\geq$ **soglia_approva** (default 80); **RIVEDI** se tra 60 e 80; **BLOCCA** se < 60 .

Le soglie (80/60) e i pesi sono in `config_param`, tarabili senza deploy.

5. Human-in-the-loop

Va all'**umano** (Responsabile Marketing o nutrizionista capo) quando: - c'è un **claim di salute** (sempre nutrizionista capo); - punteggio **incerto** vicino alle soglie (es. 58-62 o 78-82); - **newsjacking** (contenuto reattivo a una notizia); - primo contenuto di una **nuova campagna/angolo** (approvazione pilota). Il resto scorre in automatico. Ogni override umano è loggato e **rieduca** il ruleset.

6. Audit log (formato)

Ogni decisione, immutabile (append-only, coerente con l'audit del backend):

```
{ ts, asset_id, canale, verdetto, punteggio, violazioni[], ruleset_version,
  deciso_da: giudice|umano, override_di?, motivazione }
```

Serve per: difendersi da contestazioni, misurare il tasso di blocco, migliorare la libreria.

7. Configurazione (config_param)

- `giudice_ruleset` (JSON versionato delle regole §3) · `giudice_pesi` · `giudice_soglia_approva` (80) · `giudice_soglia_rivedi` (60) · `giudice_canali_attivi`.
- **Aggiornamento policy**: quando Meta/TikTok/Google cambiano le regole, si aggiorna il ruleset (nuova versione) — il Giudice applica subito le nuove regole a tutti i contenuti successivi.

8. Pseudocodice

```
function giudica(asset):  
    v = raccogli_violazioni(asset, ruleset[asset.canale]) # §3  
    if any(v.gravita == ROSSO): return blocca(v)  
    if contiene_claim_salute(asset): return rivedi(v, richiede_umano=True, escalation="nutrizionista_capo")  
    score = pesa(dimensioni(asset)) # §4  
    if any(v.gravita == ARANCIO): return rivedi(v)  
    if score >= soglia_approva:  
        if serve_pilota(asset): return rivedi(v, richiede_umano=True)  
        return approva(score)  
    if score >= soglia_rivedi: return rivedi(v)  
    return blocca(v)
```

9. Metriche del Giudice

Tasso di **approvazione/rivedi/blocco**, tempo medio di giudizio, % contenuti che superano poi il controllo delle piattaforme (zero rifiuti = obiettivo), numero di override umani (se alto → ruleset o libreria da migliorare).

10. Manutenzione e limiti

Le policy dei social **cambiano spesso e non sono sempre esplicite**: il ruleset va rivisto periodicamente e il Giudice resta un **filtro di rischio**, non una garanzia legale. Per i claim delicati decide sempre l'**umano** competente. Il Giudice riduce drasticamente il rischio di blocco, ma la responsabilità finale sui contenuti sensibili resta umana.

In una riga

Un controllo automatico che, prima di ogni pubblicazione, verifica le regole di Meta/TikTok/Google e del brand, dà un punteggio e un verdetto **Approva/Rivedi/Blocca**, manda all'umano solo il sensibile e **registra tutto** — implementabile con regole in `config_param` e audit log, così si aggiorna quando le policy cambiano.